

גנטיקה בעידן הרפואה האישית | פרויקט מסכם (04553072)

קבוצה: 15

תוכן עניינים

2	חלק 1
2	שאלה 1
3	שאלה 2
4	חלק 2
4	שאלה 2
5	חלק 3
5	שאלה 1
7	שאלה 2
7	שאלה 3
12	חלק 4
12	שאלה 1
13	שאלה 2
13	שאלה 3
14	חלק 5
14	שאלה 1
15	שאלה 2
16	דיון

חלק 1

שאלה 1

פנוטיפ 1

ID 881: Striatum volume, dorsal striatum, bilateral and adjusted for shrinkage, age, sex, plane of section, and BXD group/epoch [mm³]

אופן המדידה

נפח הסטריאטום הגבי (caudate-putamen, ללא ה-nucleus accumbens) הוערך בשיטת Cavalieri point counting על כל חתך עשירי (celloidin, כ-30 מיקרומטר), ללא תלות בזן ובמין. הנפחים תוקנו לכיוון היסטולוגי באמצעות נפח המוח בעת הקיבוע. נפחו של כל פרט עבר רגרסיה כנגד גיל, מין, מישור החיתוך, ה-BXD epoch (זני Taylor לעומת UTHSC) ומשקל המוח ללא הסטריאטום, והתכונה היא ממוצע השאריות לכל זן.

תנאי הניסוי

342 עכברים צעירים (100 – 50 ימים; 176 נקבות, 166 זכרים) מ-53 זני BXD וזני ההורים (B6, D2), שהתקבלו מה-Mouse Brain Library. המוחות קובעו בפרפוזיה, נשקלו, הוטמעו ב-celloidin ונחתכו במישור קורונלי או אופקי. התכונה היא ממוצע הזן.

פנוטיפ 2

ID 1231: Morphine response (50 mg/kg i.p.), locomotion from 0-180 min (total activity over the 3 hour test) after injection in an activity chamber, females [cm]

אופן המדידה

סך המרחק האופקי (בס"מ) בשלוש השעות שלאחר הזרקה יחידה i.p. של מורפין סולפט (50 מ"ג/ק"ג), באמצעות מדידה פוטואלקטרית של מרחק התנועה במרווחים של 15 דקות. תכונה 1231 היא הסכום על פני כל חלונות המדידה עבור נקבות (החלונות הבודדים הם תכונות 1219, 1222, 1223).

תנאי הניסוי

כחלק מה-Tennessee Mouse Genome Consortium, העוסק באפיון פנוטיפי בתפוקה גבוהה (high-throughput) של כ-70 זני BXD, במסגרת מערך ניסויי המורפין של אוניברסיטת ממפיס. נקבות נבדקו בגיל 8 – 9 שבועות, כ-6 עכברים לזן, לאחר שבוע אקלים לפחות, במחזור אור/חושך של 14 : 10.

שאלה 2

נבחרו: היפותלמוס (GSE36674) וכבד (GSE17522).

- היפותלמוס: רקמת המוח היחידה הזמינה, ושני הפנוטיפים הם תכונות מוחיות. נפח הסטריאטום הוא תכונה מורפולוגית של מערכת העצבים המרכזית. השפעות ציס-רגולטוריות על ביטוי גנים משותפות במידה רבה בין אזורי מוח, ולכן ביטוי בהיפותלמוס משמש מדד מייצג (proxy) להשפעות כלל-מוחיות של לוקוס. תנועתיות מושרית-מורפין מתווכת בעיקר דרך קולטני מיו-אופיואיד, המבוטאים בצפיפות בהיפותלמוס.
- כבד: מורפין מפונה בעיקר בגלוקורונידציה בכבד (אנזימי UGT), ולכן הבדלי ביטוי בכבד משנים את החשיפה האפקטיבית לסם ובכך את התגובה התנועתית. עבור נפח הסטריאטום, כותבי המאמר של פנוטיפ 1 (Rosen et al., Genes Brain Behav 2009; PMID 19191878) מדווחים שהמתאם החזק ביותר לנפח המתוקן הוא רוויון טרנספרין ($r = 0.66$). טרנספרין מסונתז בכבד, ולכן הכבד הוא רקמת ביניים סבירה גם עבור תכונה זו.

חלק 2

שאלה 2

SNP-ים מובהקים: תיקון BH-FDR $q < 0.05$ על פני 3,796 ה-SNP-ים (הפייפליין כמפורט בסעיפים (a-d) 3.1).
פנוטיפ 881:

- 24 סניפים מובהקים, כולם ב-QTL יחיד על כרומוזום 6 (77.5-94.6 Mb).
- הסניף המוביל: rs3661039 (כרומוזום 6, 90.3 Mb), $P = 1.5 \cdot 10^{-5}$, $q = 0.012$. זה ה-QTL על כרומוזום 6 שדווח במאמר המקורי עבור נפח הסטריאטום המתוקן.

פנוטיפ 1231:

- 38 סניפים מובהקים בארבעה אזורי QTL:
 - כרומוזום 10, 3.3-19.8 Mb – 25 סניפים, המוביל rs3721803, $p = 1.9 \cdot 10^{-6}$, $q = 0.0018$.
 - כרומוזום 11, 98.6-100.5 Mb – 6 סניפים, המוביל rs13481186, $p = 2.3 \cdot 10^{-5}$, $q = 0.011$.
 - כרומוזום 5, 145.3-147.4 Mb – 5 סניפים, המוביל mCV25009162, $p = 4.3 \cdot 10^{-4}$, $q = 0.048$.
 - כרומוזום 5, 14.0-14.2 Mb – 2 סניפים, המוביל rs6404215, $p = 3.5 \cdot 10^{-4}$, $q = 0.048$.
- סניפים מובהקים שכנים בתוך אזור כלשהו נושאים דפוסי גנוטיפ כמעט זהים בין הזנים (תאחיזה), ולכן כל QTL מיוצג על-ידי כמה סניפים בעלי אותו p -value.

חלק 3

שאלה 1

שתי הדאטאסטים הורדו באמצעות GEOparse, ולא בוצע נרמול מחדש: הניתוח משתמש בערכי הביטוי בדיוק כפי שהופקדו ב-GEO, שכבר מנורמלים. בשני מערכי הנתונים, מערך (array) הוא דגימת RNA אחת שעברה היברידיזציה, ולכן יש בדרך כלל שני מערכים (זכר ונקבה), הממוצעים רק בסוף (שלב h).

היפותלמוס, GSE36674: פלטפורמת Affymetrix Mouse Gene 1.0 ST (GPL6246), 89 מערכים. הערכים שהופקדו הם עוצמות ביטוי $\log_2$ מנורמלות RMA.

כבד, GSE17522: פלטפורמה דו-צבעית Agilent G4121A (GPL6466), 122 מערכים. הערכים שהופקדו הם יחסי $\log_2$ מנורמלי-LOWESS של כל דגימה מול RNA ייחוס משותף.

מתוך אלה, 79 המערכים בכל רקמה השייכים לזני BXD הנמצאים בקובץ הגנוטיפים נכנסים לניתוח (שלב a-b), ושלב הסינון c-f פועלים על מטריצה של $\text{probes} \times \text{arrays}$, לפני המיצוע לפי זן של h.

(a-b)

לכל אחת משתי הסדרות (מזהה GSE), עמודת ה-VALUE של כל דגימה (מזהה GSM) אוחדה למטריצת $\text{probes} \times \text{arrays}$. הזן של כל מערך נקרא משדה ה-strain במאפייני הדגימה. המטריצה מוזגה עם טבלת האנוטציה של הפלטפורמה (מזהה GPL) לקבלת סמל הגן (gene symbol), הכרומוזום והמיקום של כל פרוב.

• **היפותלמוס:** יחידת המידה של פלטפורמה זו היא "אשכול" (transcript cluster) – קבוצת פרובים קצרים המכסים אזור משועתק אחד, המסוכמים לערך יחיד לכל מערך – והיא ממלאת כאן את תפקיד הפרוב. נשמרו רק אשכולות תעתוק מסוג "main" (במספר 28,101; היתר הם נרמול/בקרה). לפלטפורמה אין עמודת סמל גן, ולכן הסימול חולץ משדה ה-"gene_assignment". כאשר אשכול משויך לכמה גנים (כ-3,800 אשכולות) נלקח הערך הראשון, שהוא השייך הראשי של Affymetrix. סינון אשכולות אלה הייתה מאבדת גנים אמיתיים.

• **כבד:** נשמרו פרובים שאינם בקרה (20,868). נעשה שימוש ב-GENE_SYMBOL ובמיקום הפרוב 'chrN:start-end'. נשמרו רק מערכים של זני BXD הנמצאים בקובץ הגנוטיפים (79 מערכים בכל רקמה).


• **גרסת גנום (build)** – גרסת גנום הייחוס שאליה מתייחסות הקואורדינטות. מיקומים ברי השוואה רק בתוך אותה גרסה. פלטפורמת ההיפותלמוס מוערת על GRCm38 (mm10), בעוד שקובץ הגנוטיפים שקיבלנו ופלטפורמת הכבד משתמשים ב-NCBI Build 37 (mm9). מיקומי הגנים של ההיפותלמוס הומרו ל-mm9 באמצעות מיפוי ה-liftOver של UCSC (בעזרת pyliftover). מתוכם, 124 גנים לא מופו ונותרו ללא מיקום. גנים ללא מיקום (אותם 124 בהיפותלמוס, ועוד 80 בכבד) נשמרים בסריקת ה-eQTL אך אינם ניתנים לסיווג *cis* או *trans*.

(c)

שורות ללא סמל גן הוסרו. נותרו 26,710 פרובים בהיפותלמוס ו-19,272 בכבד.


(d)

ערך מרבי נמוך: שתי הפלטפורמות נמצאות בסקאלות שונות (עוצמות $\log_2$ לעומת יחסי $\log_2$), ולכן סף מוחלט משותף אינו בעל משמעות. הסף נקבע באחוזון ה-10 של הערכים המרביים לפרוב בכל דאטאסט: $\max \geq 6.10$ בהיפותלמוס (הזנב התחתון של התפלגות ה-RMA, כלומר פרובים שברמת הרקע בכל המערכים) ו- $\max \geq -0.68$ בכבד (פרובים הנמוכים לפחות פי 1.6 מהייחוס בכל המערכים). נותרו: 24,042 ו-17,348 פרובים.



(e)

סינון שונות נמוכה: לכל רקמה חושבה השונות של כל פרוב שנוטר בין 79 המערכים, והוסרו הפרובים שנכללו בעשירון התחתון של התפלגות השונות באותה רקמה ($\sigma^2 < 0.0089$ בהיפותלמוס, $\sigma^2 < 0.021$ בכבד). לפרובים בעלי שונות כל כך נמוכה צפוי לא לתרום לזיהוי eQTL, בעוד שהכללתם מגדילה את מספר המבחנים שנעשה, ובכך מובילה לתיקון multiple testing מחמיר יותר. סף של 10% נבחר כדי להסיר את הקצה בעל השונות הנמוכה, תוך שמירה על מרבית הפרובים המציגים שונות מתונה. נותרו 21,637 פרובים בהיפותלמוס ו-15,613 פרובים בכבד.



(f)

פרובים מרובים לאותו גן אוחדו ע"י שמירת הפרוב בעל השונות הגבוהה ביותר בלבד, שהוא האינפורמטיבי ביותר למבחן אסוציאציה. מיצוע פרובים היה מדלל פרוב שנמדד היטב בפרובים בעלי היברדיזציה גרועה או רוויה. תוצאה: 19,577 גנים (היפותלמוס) ו-14,659 גנים (כבד).

(g)

צמצמנו לזנים שמנצאים בקובץ הגנוטיפים ובכל מערך ביטוי (45 היפותלמוס, 40 כבד). SNP-ים עוקבים בעלי וקטור גנוטיפ זהה על פני זנים אלה (קריאות לא ידועות נספרו כערך נפרד) נותנים סטטיסטיקות אסוציאציה זהות, ולכן כל רצף של שכנים זהים יוצג על-ידי SNP אחד: 1,598 SNP-ים מייצגים לזני ההיפותלמוס ו-1,403 לזני הכבד (מתוך 3,796). זהות ה-SNP המייצג של רצף אינה משפיעה על המבחן, אלא רק על המיקום המיוחס לו, ונבחר ה-SNP הראשון.

בנוסף, נרשם הטווח (span) של כל רצף בגנום (חציון 0.4-0.5 Mb, עד 10 Mb), כך שמרחקי סניפ-גן לסיווג *cis/trans* נמדדים ביחס לתחילת/סוף הקטע ברצף ולא אל SNP שרירותי יחיד.

מערכים של אותו זן מוצעו ללא הבחנה במין (ל-34 מ-45 זני ההיפותרמוס ול-38 מ-40 זני הכבד יש מערך אחד מכל מין, ולשאר יש מערך למין אחד בלבד), וכך נוצרו מטריצות הקלט הסופיות: $19,577 \times 45$ זנים (היפותרמוס) ו- $14,659 \times 40$ זנים (כבד).

שאלה 2

מבחן האסוציאציה של חלק 2 (מיפוי eQTL = מיפוי QTL עם ביטוי של גן כתכונה): רגרסיה ליניארית של ממוצעי הזנים של גן על הגנוטיפ ($B = 0, H = 1, D = 2$) ומבחן F של הרגרסיה, עבור כל זוג גן $\times$ סניף מייצג.

• היפותרמוס: $1,598 \times 19,577 = 31.3$ מיליון מבחנים.

• כבד: $1,403 \times 14,659 = 20.6$ מיליון מבחנים.

השוואות מרובות: תיקון BH-FDR פעם אחת על כל מבחני הגן $\times$ סניף של רקמה (ערך q לכל זוג), ולא לכל גן בנפרד, כך ש- $\text{false positive rate}$ אחת חלה על אוסף ה-eQTL כולו ומספר ה-eQTLים המובהקים מוגדר היטב.

בחירת ה-eQTLים: כל זוג (גן-סניף) עם $q < 0.05$ הוא eQTL של אותו גן. גנים ללא SNP מובהק סוננו החוצה. לא צמצמנו כל גן ל-SNP הטוב ביותר שלו, משום שצמצום כזה מניח שכל ה-SNPים המובהקים של גן מסמנים את אותו לוקוס, וזה לא בהכרח נכון (לדוגמה לגן יכולים להיות eQTL מסוג *cis* ו-eQTL בלתי-תלוי מסוג *trans*). מיקום ה-eQTL הוא ה-SNP המייצג יחד עם טווח רצף ה-SNPים הזהים שלו. הסתייגות: SNP-ים שכנים בעלי קורלציה גבוהה (אך לא מושלמת) על פני הזנים נשמרים כ-eQTLים נפרדים, ולכן לוקוס יחיד מיוצג בדרך כלל ע"י כמה SNP-ים (חציון 4 SNP-ים מובהקים לגן, ולכל היותר 32), מה שמנפח את מספר ה-eQTLים ביחס למספר הלוקוסים הבלתי-תלויים.

תוצאות:

• היפותרמוס: 7,509 eQTLים (זוגות גן-סניף) עבור 1,416 גנים (מתוך 19,577 שנבדקו) ב-1,317 SNP-ים שונים (מתוך 1,598).

• כבד: 6,804 eQTLים עבור 1,285 גנים (מתוך 14,659) ב-1,209 SNP-ים שונים (מתוך 1,403).

שאלה 3


מספר eQTLים, *cis* לעומת *trans* (זוגות שהגן שלהם חסר מיקום גנומי מסווגים "unknown"):

כבד	היפותרמוס		
2,320 (34%)	3,066 (41%)	ציס	eQTLs (זוגות גן-סניף)
4,451 (65%)	4,434 (59%)	טראנס	
33	9	unknown	
6,804	7,509	סה"כ	
184	245	ציס בלבד	SNP-ים שונים בעלי eQTL
364	388	טראנס בלבד	
652	681	שניהם	
1,209	1,317	סה"כ	
198	304	ציס בלבד	גנים עם eQTL
413	288	טראנס בלבד	
674	824	שניהם	
1,285	1,416	סה"כ	

נבחין כי רוב ה-SNP-ים, ורוב הגנים, בעלי eQTL פועלים גם ב-*cis* וגם ב-*trans*.

(b)

מבין הסניפים המייצגים, 1,317 בהיפותלמוס ו-1,209 בכבד מקושרים לגן אחד לפחות (281 ו-194 ללא אף גן). ההתפלגות מוטה ימינה בחדות: 20% מהסניפים בעלי eQTL מקושרים לגן יחיד וכמחצית לכל היותר לשלושה גנים (49% היפותלמוס / 46% כבד), החציון 4 והממוצע 5.7 / 5.6, ואילו 14% מהסניפים בעלי eQTL מקושרים ליותר מ-10 גנים, עד 50 (היפותלמוס) ו-69 (כבד). אזי רוב ה-eQTLs משפיעים על גן אחד או גנים מעטים, וזנב קטן של סניפים משפיע על רבים - אלה ה-hotspots הנבחנים ב-(e). שתי הרקמות דומות באופן בולט בהיבט זה (כל השברים בטווח 3 נקודות אחוז, אותו חציון וכמעט אותו ממוצע), למרות פלטפורמות, קבוצות זנים וקבוצות גנים שונות.




(c)

לאורך הגנום, מספר הגנים המקושרים לסניף אינו אחיד - לרוב הסניפים גנים מעטים, עם מעט אזורים יוצאי דופן:

- היפותלמוס: כרומוזום 17 (~ 22-37 Mb; עד 50 גנים), כרומוזום 11 (~ 65 Mb), כרומוזום 2 (~ 115-135 Mb), כרומוזומים 1 ו-7;
- כבד: כרומוזום 12 (~ 104-110 Mb; 69 גנים), כרומוזומים 17, 2, 4 ו-8.

אלה ה-hotspots מסוג *trans* אותם מנתחים ב-(e). סניפים סמוכים מראים ספירות דומות, כנראה בשל תאחיה.




כרומוזומים מוצללים לסירוגין, כדי שגבולותיהם יהיו ברורים לעין.

(d)

התפלגויות ערכי p vals:

- eQTLs מסוג cis , ככלל, חזקים בהרבה מ- $trans$: חציון $-\log_{10}(P)$ הוא 7.2 לעומת 6.1 (היפותלמוס) ו-7.5 לעומת 6.0 (כבד).
- להתפלגות ה- cis זנב ארוך (עד $10^{-34} / 10^{-29}$) ואילו ערכי p val של $trans$ צפופים מעט מעל גבול המובהקות $-\log_{10}(P) \approx 4.9$.


תצפיות אלה תואמות את הנלמד מההרצאה, של-eQTLים מסוג cis נטייה לאפקטים גדולים יותר מאשר ל- $trans$: וריאנט רגולטורי יחיד פועל ישירות על הגן הסמוך, בעוד השפעות $trans$ עקיפות ומדוללות יותר.



(e)

מפת eQTL (מיקום סניף מול מיקום גן):

- ה-eQTLs מסוג cis יוצרים אלכסון חד (הגן במיקום ה-SNP) בשתי הרקמות.
- ה-eQTLs מסוג $trans$ מפוזרים מחוץ לאלכסון ומתרכזים בפסים אנכיים - סניפים המקושרים לגנים מרוחקים רבים, כלומר hotspots מסוג $trans$.



ערכי הסף עבור ה-hotspots הוגדרו, כמו בספרות (Morley et al. (2004), (Brem et al. (2002), מול השערת אפס שבו ה-eQTLs מסוג *trans* מפוזרים אחיד על פני הסניפים המייצגים. מספר גני ה-*trans* לכל סניף מתפלג בינומי, מקורב ע"י פואסון עם ממוצע = מספר *trans* eQTLs חלקי מספר SNPs (2.8 בהיפותלמוס, 3.2 בכבד). SNP הוא hotspot אם מספר הגנים ב-*trans* אצלו עולה על הערך המושג בהסתברות קטנה מ-0.001 תחת מודל אפס זה: יותר מ-9 גנים (היפותלמוס) ויותר מ-10 גנים (כבד).

hotspot-SNPs במרחק עד 5 Mb אוחדו לאזורים. מודל האפס שתיארנו מניח eQTLs בלתי-תלויים ולכן הוא מקל (ראו חלק 5). הסף משמש לדירוג ולסימון hotspots מועמדים, והבולטים שבהם (64 – 20 גני *trans*) בולטים תחת כל כלל סביר.

• היפותלמוס: 118 hotspot-SNPs ב-29 אזורים, החזקים שבהם:

- כרומוזום 17: 22-37 Mb (שיא 40 גני *trans*, rs13482930)
- כרומוזום 11: 65-75 Mb (27)
- כרומוזום 7: 71-74 Mb (24)
- כרומוזום 17: 9-12 Mb (23)
- כרומוזום 12: 27-29 Mb (22)
- כרומוזום 2: 114-136 Mb (22).

• כבד: 93 hotspot-SNPs ב-30 אזורים, עם hotspot דומיננטי אחד בכרומוזום 12: 104-110 Mb (שיא 64 גני *trans*, rs13481620), ואחריו:

- כרומוזום 17: 27-41 Mb (22)
- כרומוזום 2: 107-126 Mb (21)
- כרומוזום 8: 75-78 Mb (20)

– כרומוזום 11: 72-75 Mb (19).

כמה מאזורי ה־hotspots משותפים לשתי הרקמות (כרומוזום 17 סביב 27-37 Mb ו־9-12 Mb, ובכרומוזומים 11, 2, ו־1), ואילו ה־hotspot בכרומוזום 12 ייחודי לכבד.

חלק 4

סריקת ה-QTL השתמשה בכל 3,796 הסניפים, ואילו כל סריקת eQTL השתמשה בסניפים המייצגים של קבוצת הזנים שלה. ההשוואה נעשית לכן על פני כל 3,796 הסניפים, כאשר סניף הוא eQTL-SNP של רקמה אם לסיף המייצג שעמד במקומו (גנוטיפים זהים על פני זני אותה רקמה) יש לפחות eQTL מובהק אחד. סניף הוא QTL-SNP אם הוא מובהק ($q < 0.05$) עבור פנוטיפ 881 או 1231 ($62 = 38 + 24$) סניפים, על כרומוזומים שונים).

שאלה 1


כן: כל 62 ה-QTL-SNPs הם eQTL-SNPs בלפחות רקמה אחת - 56 בשתי הרקמות, 2 בהיפותלמוס בלבד, 4 בכבד בלבד, 0 באף אחת.

לפי פנוטיפ:

- 881 (ה-QTL בכרומוזום 6): 22 מתוך 24 סניפים הם eQTLs בכל רקמה (20 בשתיהן)
- 1231 (ה-QTLs בכרומוזומים 5/10/11): 36 מתוך 38 בהיפותלמוס, וכל ה-38 בכבד.

על פני הגנום כולו:

- QTL בלבד 0
- eQTL היפותלמוס בלבד 262
- eQTL כבד בלבד 439
- eQTL בשתי הרקמות 2,887
- QTL ושתי קבוצות ה-eQTL 56
- QTL ו-eQTL היפותלמוס 2
- QTL ו-eQTL כבד 4
- אף קבוצה 146.



כלומר 3,650 מתוך 3,796 סניפים (96%) הם eQTL-SNPs בלפחות רקמה אחת, וה-QTL-SNPs (100%) אינם מועשרים באופן בולט מעל רק זה.

שאלה 2

עבור זיהוי QTLs – הכרעה אילו סניפים מקושרים לפנוטיפ – נתוני הביטוי הוסיפו כאן מעט: עם 40-45 זנים, אלפי גנים ו-QTLs המוגדרים ברמת הסניפים המייצגים, 96% מכלל הסניפים הם eQTL של גן כלשהו, ולכן “להיות eQTL” אינו מבחין בין QTL-SNPs לשאר הגנום. ה-QTLs נמצאו ע”י סריקת הפנוטיפ לבד, וכל QTL-SNP היה עובר מסנן eQTL, אבל כך גם כמעט כל SNP שאינו QTL. נתון ה-96% תלוי בהגדרות שלנו: מכיוון שכל SNP מובהק של גן נספר כ-QTL, eQTL חזק מסוג *cis* מסמן את כל סביבת התאחיזה שלו (חציון 4 סמנים לגן), ומפת הסמנים הדלילה (SNP מייצג אחד לכל 1.6Mb, כלומר 15-20 גנים) גורמת לכך שכמעט כל חלון סמן מכיל גן כלשהו בעל eQTL. עם eQTL-SNP אחד לכל גן הכיסוי היה כ-40% מהסניפים המייצגים בכל רקמה וכ-60% מהגנום לשתי הרקמות יחד – נמוך יותר, אך המסקנה הייתה נותרת זהה.

הערך המוסף הוא בפרשנות של ה-QTLs: QTL הוא אזור של כמה Mb המכיל עשרות גנים, וסריקת הפנוטיפ אינה יכולה לומר מי מהם החשוב. ה-QTLs מצמצמים זאת לגנים שביטויים נשלט גנטית מאזור ה-QTL ברקמה רלוונטית – למשל *Nfu1*, *Nup210* ו-*Anxa4* ב-QTL של נפח הסטריאטום בכרומוזום 6, או *Cyp3a25* (אנזים ציטוכרום P450 מפרק-תרופות) בכבד ב-QTL של תנועתיות המורפין בכרומוזום 5 – והם מספקים את פנוטיפ הביניים הדרוש לבדיקה האם ה-QTL פועל דרך ביטוי גנים (חלק 5). לכן, נתוני ביטוי הם בעלי ערך מועט כמסנן לגילוי QTLs בהקשר זה, אך בעלי ערך ניכר במעבר מ-QTL לגנים מועמדים ולמנגנונים.

שאלה 3

צדדים חיוביים:

- תעדוף ופרשנות: וריאנט שהוא eQTL מגיע עם גן מועמד ומנגנון (שינוי ביטוי), שזה בדיוק מה שנדרש להמשך המחקר.
- עוצמה סטטיסטית: אם קבוצת ה-eQTL היא חלק קטן מכלל הוריאנטים, הגבלת הסריקה מפחיתה את כמות המבחנים המרובים (multiple testing) ומאפשרת לאפקטים חלשים יותר לעבור את סף המובהקות.

צדדים שליליים:

- אין צמצום בפועל. בנתונים שלנו 96% מהסניפים הם eQTLs של לפחות גן אחד כאשר נבדקות שתי רקמות ואלפי תעתיקים, כך שהמסנן כמעט אינו מסיר דבר ותוספת העוצמה אפסית. עם יותר רקמות הכיסוי היה מתקרב ל-100%.
- אובדן אסוציאציות אמיתיות: וריאנטים הפועלים דרך מנגנונים שאינם רמת mRNA במצב יציב (שחבור, יציבות חלבון, RNA לא-מקודד...) או דרך ביטוי ברקמה, סוג תא, שלב התפתחותי או תנאי שלא נדגמו – היו מוחמצים. קבוצת ה-eQTL תלויה לחלוטין ברקמות שנמדדו.
- תאחיזה: בעכברי BXD, eQTL-SNP מתייג בלוק הפלוטיפ של כמה Mb, והעובדה שהבלוק מכיל eQTL אינה אומרת ששינוי הביטוי נמצא על המסלול הסיבתי אל הפנוטיפ (מה שמסתכלים בחלק 5).

מסקנה: באסוציאציות ביטוי יש להשתמש כדי להעיר ולדרג וריאנטים של GWAS ולבחור גנים מועמדים, לא כמסנן קשיח הקובע אילו וריאנטים ייבדקו.

חלק 5

שאלה 1

(a)

המודל: עבור לוקוס L (הגנוטיפ של הסניף - $B/H/D$), גן R (ממוצעי הזנים של ביטוי הגן) והתכונה המורכבת C (ממוצעי הזנים של הפנוטיפ), מושוים שלושה מודלים סיבתיים, לפי מה שראינו בהרצאה:

$$\begin{array}{lll} P(L)P(R|L)P(C|R) & L \rightarrow R \rightarrow C & M1 \text{ (סיבתי / תיווך)} \\ P(L)P(C|L)P(R|C) & L \rightarrow C \rightarrow R & M2 \text{ (תגובתי)} \\ P(L)P(R|L)P(C|L) & L \rightarrow R, L \rightarrow C & M3 \text{ (בלתי תלוי)} \end{array}$$

לפי $M1$ הלוקוס משפיע על התכונה רק דרך ביטוי הגן, לפי $M2$ הביטוי מגיב לתכונה, ולפי $M3$ הלוקוס משפיע על שניהם באופן בלתי תלוי (הקשר בין R ל- C מוסבר אז ע"י הלוקוס המשותף, כלומר תאחיזה ולא תיווך).

התפלגויות מותנות: משתנה בהינתן הגנוטיפ הוא גאוסי עם ממוצע ושונות לכל קבוצת גנוטיפ $Y|L \sim N(\mu_L, \sigma_L^2)$, כמו בהרצאה. משתנה בהינתן משתנה רציף הוא גאוסי סביב קו רגרסיה $Y|X \sim N(aX + b, \sigma^2)$, ו- $P(L)$ הוא שכיחות הגנוטיפ האמפירית (זהה בכל המודלים).

כל הפרמטרים הם אומדני נראות מרבית (ממוצעי קבוצות, קו ריבועים פחותים, שונות MLE), המחושבים בפונקציות שכתבנו בעצמנו (ללא ספריית רשתות בייסיאניות, ע"פ ההנחיות). נראות המודל היא המכפלה על פני הזנים שיש להם גנוטיפ, ביטוי ופנוטיפ (28-39 זנים לשלשה). קבוצות גנוטיפ עם פחות מ-3 זנים (הטרוזיגוטים נדירים) אינן יכולות לתמוך באומדן שונות, ולכן הזנים שלהן הוצאו מהשלשה (1-2 זנים הטרוזיגוטיים ב-25 מתוך 104 השלשות).

השוואת המודלים: למודלים מספרי פרמטרים שונים (למשל ל- $C|L$ יש ממוצע לכל קבוצת גנוטיפ ואילו ל- $C|R$ שיפוע וחיתוך), ולכן הם מושוים באמצעות $AIC = 2k - 2\ln L$. היחס החזוי הוא המודל בעל ה- AIC הנמוך ביותר, ו- $\Delta AIC = AIC - AIC_{\text{best}}$ של המודל השני בטיבו פחות ה- AIC של הטוב ביותר מודד את המרווח.

השלשות שנבדקו: כל זוג (גן, פנוטיפ) שה-eQTL-SNP שלו (או רצף ה-SNPs הזהים שלו) נמצא בתוך 2 Mb מ-QTL-SNP של הפנוטיפ, בכל אחת מהרקמות - 104 שלשות:

• פנוטיפ 881:

- 16 גנים בהיפותלמוס (13 ציס, 3 טראנס)
- 27 גנים בכבד (8 ציס, 18 טראנס, גן אחד ללא מיקום)

• פנוטיפ 1231

- 25 גנים בהיפותלמוס (15 ציס, 10 טראנס)
- 36 בכבד (20 ציס, 16 טראנס).

עבור גן עם כמה סניפים מתאימים נלקח כ- L הסניף בעל ה-eQTL החזק ביותר.

(b)

פנוטיפ	רקמה (מס' גנים)	$M1 \quad (L \rightarrow R \rightarrow C)$	$M2 \quad (L \rightarrow C \rightarrow R)$	$M3 \quad (L \rightarrow R, L \rightarrow C)$
881	היפותלמוס (16)	2	0	14
881	כבד (27)	12	0	15
1231	היפותלמוס (25)	4	0	21
1231	כבד (36)	17	0	19
הכל	104	35	0	69

עבור 69 מתוך 104 השלשות המודל הבלתי תלוי $M3$ הוא המתאים ביותר (חציון $\Delta AIC = 3.3$), כלומר הלוקוס משפיע על הגן ועל הפנוטיפ בנפרד והגן אינו חזוי לתווך את ה-QTL. המודל התגובתי $M2$ (ביטוי המושפע מפנוטיפ) אינו מועדף אף פעם, ואף אינו במקום השני אף פעם, כצפוי מתכונות אנטומיות והתנהגותיות שאינן סבירות כמניעות ביטוי במצב יציב. מודל התיווך $M1$ מנצח ב-35 שלשות, אם כי לרוב במרווח קטן (חציון $\Delta AIC = 0.8$; עם 10 שלשות בלבד מעל 2). קריאות ה- $M1$ החזקות ביותר:

• פנוטיפ 881 (נפח סטריאטום), QTL כרומוזום 6:

– *Polr1a* (היפותלמוס, *cis*, $\Delta AIC = 1.6$)

– *Vamp5* (כבד, *cis*, 4.4), *Tgoln2* (4.2), *Mrpl35* (3.9)

– *Ggcx* (כבד, *trans*, 3.8)

– *Ptcd3* (היפותלמוס, *cis*, 3.0)

• 1231 (תנועתיות מורפין):

– *Gpr12* (כבד, *cis*, QTL כרומוזום 5, 5.0),

– *Smarce1* (כבד, *cis*, QTL כרומוזום 11, 2.7)

– *Lsm12* (כבד, *cis*, 2.5),

– *A430033K04Rik* (היפותלמוס, *trans*, 2.1).

אם כך, המועמדים החזקים ביותר לתיווך עבור נפח הסטריאטום הם *Polr1a* (הקריאה המובילה, וברקמת המוח) והקבוצה *Vamp5/Tgoln2/Mrpl35* – שלושה גנים שכנים ב-*cis* בכבד, בקטע 86-89 Mb בכרומוזום 6, החולקים אותו SNP (mhcCD8b4), כלומר אות אחד ברמת הלוקוס ולא שלושה מתווכים בלתי-תלויים. עבור תנועתיות מושרית-מורפין המועמד החזק ביותר הוא *Gpr12* (גן *cis* ב-QTL כרומוזום 5, 147 Mb).

שאלה 2

(a)

בתכנון, השאלה המעניינת היא האם ההעדפה ל- $M1$ (תיווך) יכולה להיווצר במקרה כאשר האמת היא $M3$ (הלוקוס משפיע על הגן ועל הפנוטיפ באופן בלתי-תלוי). השערת האפס היא לכן תהיה $M3$, ועל הפרמוטציה להרוס בדיוק את התלות בין R ל- C שמעבר ללוקוס המשותף, תוך שמירה על כל השאר: ערכי הפנוטיפ עורבבו בין הזנים בתוך כל קבוצת גנוטיפ. כך $P(L)$ והתאמות $R|L$ ו- $C|L$ נותרים ללא שינוי כלל (כל קבוצת גנוטיפ שומרת על אותה קבוצת ערכי פנוטיפ) ורק התלות המותנית של C ב- R בהינתן L נשברת - דגימה ממודל האפס שבו ה-QTL וה-eQTL מתקיימים יחד אך הביטוי אינו מתווך. ערבוב חופשי של הפנוטיפ בין כל הזנים היה הורס גם את ה-QTL ($C|L$) ובודק השערת אפס חלשה בהרבה: כל מערך נתונים מעורבב היה חסר אפילו את מבנה ה-QTL, ולכן ערכי T_{perm} היו נמוכים באופן שיטתי ושלושה הייתה נראית מובהקת רק משום שיש לה QTL - מה שמנפח תוצאות שהן false positives.

המחיר של ערבוב בתוך הקבוצות הוא **מרחב פרמוטציות קטן יותר**, אך עם קבוצות גנוטיפ של כ-25-10 זנים מספר הפרמוטציות השונות בתוך הקבוצות עדיין עולה בהרבה על $B = 1,000$, כך שרזולוציית המבחן אינה נפגעת.

סטטיסטי המבחן: יתרון ה- AIC של $M1$ על הטוב מבין $M2$ ו- $M3$,

$$T = \min(AIC_{M2}, AIC_{M3}) - AIC_{M1}$$

המקבילה ב- AIC למבחן יחס-הנראות מההרצאה של $M1$ מול $\max(M2, M3)$, תוך שימוש ב- AIC במקום בנראויות גולמיות כדי שמספרי הפרמטרים השונים של המודלים יישארו מטופלים. חישוב $pval$:

$$pval = \frac{1 + \# \{T_{perm} \geq T_{obs}\}}{B + 1}$$

עם $B = 1,000$ פרמוטציות (ו-*seed* קבוע לשחזור).

(b)

מכיוון שזמן הריצה לא היווה צוואר בקבוק (כדקה אחת), המבחן הורץ על כל 104 השלשות, כלומר עבור כל שלשה נשאלת השאלה האם יש עדות מובהקת לתיווך מול השערת האפס $M3$ - עבור 69 השלשות שחזויות $M3$ התשובה הצפויה שלילית, וקבלתה מאשרת את העקביות בין שני הניתוחים.

תוצאות: 3 מתוך 104 מגיעות ל- $p < 0.05$, כולן גני *cis* שחזויים $M1$:


• *Polr1a* (פנוטיפ 881, היפותלמוס; $p = 0.010$)

• *Gpr12* (פנוטיפ 1231, כבד; $p = 0.033$)

• *Mrpl35* (פנוטיפ 881, כבד; $p = 0.034$)

המועמדים הבאים ($p = 0.052$ - *Vamp5*, $p = 0.065$ - *Tgoln2* / *Ptcd3*) נופלים מעט מתחת לסף, ואף שלשה שחזויה $M3$ אינה מגיעה למובהקות (הקרובה ביותר $p = 0.054$).

לאחר תיקון BH על פני 104 המבחנים אף שלשה אינה נותרת מובהקת (ה- q הקטן ביותר 0.81): עם 28-39 זנים המחקר חסר עוצמה לביסוס תיווך עבור גן בודד ב-FDR מבוקר. הדירוג בכל זאת תואם את ניתוח ה- AIC : העדות הנומינלית החזקה ביותר לתיווך היא *Polr1a* (נפח סטריאטום, כרומוזום 6) ו-*Gpr12* (תנועתיות מורפין, כרומוזום 5).



פנוטיפ מול ביטוי של שני המועמדים המובילים, נקודות צבועות לפי גנוטיפ עם קו רגרסיה לכל קבוצה.

נקודת הכיתוב: תחת תיווך ($M1$) הקשר ביטוי-פנוטיפ נשמר בתוך כל קבוצת גנוטיפ, וזה מה שפאנל ה-*Polr1a* מראה.

דיון

האם התוצאות תואמות את הציפיות?

במידה רבה כן.

1. רוב השלשות (69 מתוך 104) מסווגות בלתי תלויות ($M3$): תכונה אנטומית או התנהגותית צפויה להיות מושפעת מגורמים רבים, ולכן רוב הגנים החולקים לוקוס עם ה-QTL הם בתאחיזה אליו ולא מתווכים ישירות.

2. המודל התגובתי $M2$ אינו מנצח אף פעם - נפח מוח במצב יציב או תגובה התנהגותית הנמדדת בנפרד אינם יכולים באופן סביר להניע ביטוי בכבד או בהיפותלמוס, והמבחן מסכים עם זה.

3. מועמדי התיווך הגיוניים ביולוגית: כמעט כולם גני eQTL מסוג *cis* (האפקטים החזקים והישירים), ושני המועמדים המובילים יושבים בדיוק היכן שמתווכים אמורים לשבת - *Polr1a* תחת ה-QTL של נפח הסטריאטום בכרומוזום 6 ברקמת מוח, ו-*Gpr12* (brain-enriched GPCR) תחת ה-QTL של תנועתיות המורפין בכרומוזום 5.

4. העובדה שאף מועמד אינו שורד את תיקון ה-FDR היא מחיר הגיוני של שימוש בכ-40 זנים וממוצעי זנים: אות התיווך הוא אפקט מסדר שני (הפרש בין התאמות של מודלים), וגודל פאנל ה-BXD מגביל את העוצמה. נתייחס לזה בשיפורים, בהמשך.

בעיות ושיפורים אפשריים

1.

הרכב המינים של נתוני הביטוי. הביטוי מוצע לכל זן ללא הבחנה במין. לרוב הזנים יש מערך זכר ומערך נקבה, אך 11 זני היפותלמוס (6 זכרים בלבד, 5 נקבות בלבד) ו-2 זני כבד (BXD11 זכר בלבד, BXD33 מכיל שני מערכי נקבה) הם מייצגים רק מין אחד. עבור גנים שמושפעים ממין הפרט (רבים הן בהיפותלמוס הן בכבד) הממוצעים של זנים אלה מוסטים ביחס לזנים המעורבים, מה שעלול ליצור eQTLs מדומים או להסוות אמיתיים. בנוסף, פנוטיפ 1231 הוא של **נקבות בלבד**, בעוד ממוצעי הביטוי מעורבי-מין, כך שמבחן התיווך מזווג תכונה נקבית עם ביטוי ממוצע על פני שני המינים. מדדנו את שתי הדאגות (מחברת סעיף 5.3), עם תוצאות הפוכות:

1. חזרנו על הניתוח לאחר **הסרת הממוצע הפר-מיני** של כל גן מהמערכים (sex-centring) לפני המיצוע לפי זן. ההשפעה שקיבלנו היא קטנה בכל רמה. שתי הריצות מסכימות על 96% (היפותלמוס) ו-95% (כבד) מזוגות ה-eQTL המובהקים שנמצאו על-ידי מי מהן: בהיפותלמוס 7,362 מתוך 7,509 הזוגות המקוריים נותרים מובהקים, 147 אובדים ו-143 מתווספים; בכבד 6,652 מתוך 6,804 נותרים, 152 אובדים ו-202 מתווספים. כל 35 השלשות שסווגו M1 שומרות על הסיווג, וערכי ה-pvals של הפרמוטציה של המועמדים המובילים כמעט ללא שינוי (*Polr1a*) $0.010 \rightarrow 0.035$ *Gpr12*, $0.033 \rightarrow 0.010$.

2. חזרה על מבחני התיווך של 1231 עם ביטוי **נקבות בלבד** משנה את הסיווגים במידה ניכרת – רק 11 מתוך 21 קריאות ה-M1 נותרות M1 (10 עוברות ל-M3; 4 קריאות M3 עוברות ל-M1 ואחת ל-M2), ו-*Gpr12* נחלש מ- $p = 0.033$ ל- $p = 0.228$. חלק מכך הוא כנראה תוצאה של היחלשות (attenuation) ולא של ביולוגיה תלויה מין: ממוצעי נקבות בלבד נשענים על מערך יחיד לזן במקום שניים, והדאטא מהזנים הזכריים בלבד אובד (39 לעומת 45 זנים בהיפותלמוס). ובכל זאת, קריאות התיווך של 1231 רגישות למין של נתוני הביטוי – כפי שהן רגישות לסקאלת הפנוטיפ (ראו מגבלת תלות הסקאלה בהמשך) – מה שמחזק שיש להתייחס אליהן כהצעות ולא כממצאים.

2.

סניפים מייצגים הוגדרו ע"י מיזוג שכנים בעלי גנוטיפים זהים בלבד (שלב g) 3.1, כך שסניפים בעלי קורלציה גבוהה אך לא מושלמת על פני 40-45 הזנים נותרים נפרדים. כתוצאה מכך לגן יש בדרך כלל כמה סניפים מובהקים על אותו כרומוזום (חציון 4; 99% – 98% מזוגות הסניפים המובהקים של גן הם על אותו כרומוזום, חציון r^2 של הגנוטיפ 0.65), וספירות ה-eQTL של חלק 3 הן ספירות של זוגות גן-סניף ולא של לוקוסים בלתי-תלויים. LD clumping של ה-SNPs המובהקים של כל גן (השמטת SNPs עם $r^2 \geq 0.8$ לטובת SNP מובהק יותר של אותו גן על אותו כרומוזום; מחברת סעיף 5.3) מצמצם את 7,509 זוגות ההיפותלמוס ו-6,804 זוגות הכבד ל-3,346 ו-3,013 לוקוסים בלתי-תלויים (חציון 2 לוקוסים לגן; ל-40% מהגנים לוקוס יחיד). מכאן שספירות ה-eQTL של חלקים 3-4 הן ברמת הסמן ומפריזות במספר האותות הרגולטוריים השונים. הדבר מנפח את מספר ה-eQTLs לכל hotspot ואת חלק הגנום המכוסה על-ידי eQTLs (ה-96% של חלק 4), אך אינו משפיע על אילו גנים הם בעלי eQTL או על מועמדי חלק 5 (ה-SNP החזק ביותר של כל גן אינו משתנה ב-clumping). גם אף ערך *pval* או *q* מדווח אינו משתנה, שכן ה-clumping מקבץ זוגות אחרי המבחנים ותיקון ה-BH שלהם.

3.

תלות סקאלה (scale) של מבחן התיווך: מודל התיווך הגאומטרי-ליניארי אינו אינווריאנטי לשינוי סקאלה מונוטוני של המשתנים – טרנספורמציה משנה את הנראויות ויכולה לשנות איזה מודל מנצח. כדי למדוד זאת חזרנו על המבחן עבור כל 61 השלשות של פנוטיפ 1231 עם פנוטיפ בטרנספורמציה לוג (מחברת סעיף 5.3). אף סקאלה אינה ה"נכונה" – ממוצעי הזנים של 1231 למעשה כמעט סימטריי (skew של 0.18; הלוג מתקן יתר על המידה ל-1.43) – ולכן הבדיקה מודדת עמידות ולא מתקנת הפרה. הסיווגים מתגלים כשבירים: מתוך 21 השלשות שסווגו M1 בסקאלה הגולמית רק 3

נותרות $M1$ תחת הלוג (כולן היפותלמוס: $Cpsf4$, $A430033K04Rik$, $Mmd2$). כל 17 קריאות ה- $M1$ בכבד עוברות ל- $M3$, וערך ה- $pval$ של הפרמוטציה של $Gpr12$ נחלש מ-0.033 ל-0.115. את מועמדי התיווך של 1231 יש לכן לקרוא בזהירות, כאשר שלישית ההיפותלמוס העמידה לטרנספורמציה היא ההגנתית ביותר. מועמדי נפח-הסטריאטום חשופים פחות (ממוצעי הזנים של 881 סימטריים, skew של 0.02, כך ששום שינוי סקאלה אינו מתבקש).

.4

עוצמת מבחן התיווך – המבחן משתמש בממוצעי זנים של כ-30-40 זנים ולכן מוותר על השונות התוך-זנית שנתונים ברמת הפרט היו מספקים. בגודל מדגם זה אות התיווך (הפרש בין התאמות של מודלים) רק לעיתים רחוקות עובר תיקון השוואות מרובות, כפי שנראה בשאלה 2. יותר זנים, נתונים ברמת הפרט, ויותר פרמוטציות לרזולוציית $pval$ עדינה יותר – כולם יעלו את העוצמה.

.5

שני מערכי הביטוי הם מדדים מייצגים (proxies) לרקמות שבהן התכונות נוצרות: נפח הסטריאטום (881) זוג עם היפותלמוס כרקמת המוח היחידה הזמינה, והתגובה התנועתית (1231) מתווכת על-ידי מעגלים סטריאטליים ולא על-ידי היפותלמוס או כבד. תיווך דרך ביטוי הוא תלוי רקמה, ולכן גן המתווך את ה-QTL ברקמה הרלוונטית אך אינו מבוקר ע"י הלוקוס ברקמות שנדגמו מוחמץ לחלוטין. נתוני ביטוי מהרקמות הרלוונטיות לתכונות (סטריאטום בשני המקרים) היו הופכים את המבחן לרגיש יותר ואת המועמדים ליותר קלים לפרשנות.

.6

hotspots מסוג $trans$ סווגו מול התפלגות אחידה (פואסון) של $trans$ eQTLs על פני ה-SNPs. מודל אפס זה מניח ש-eQTLs נופלים על SNPs באופן בלתי תלוי, הנחה המופרת בשתי דרכים: SNPs בתאחיזה חולקים את גני המטרה שלהם, וגנים בעלי ביטוי מתואם חולקים את ה-eQTLs שלהם, כך שרגולטור חזק יחיד (או מודול גנים מתואם) יכול לייצר לבדו ספירה גדולה בלוקוס אחד. הסף לכן מקל, ואין לפרש יתר על המידה את מספרם המדויק של ה-hotspots. האזורים החזקים ביותר (כרומוזום 17 בהיפותלמוס, כרומוזום 12 בכבד) עמידים לבחירת הכלל (הם גם עוברים את האחוזון ה-99 האמפירי של הספירות). מבחן פרמוטציה המערבב את תוויות הזנים של מטריצת הביטוי כולה – תוך שימור מתאמי גן-גן – והלוקח את ה-hotspot הגדול ביותר בכל פרמוטציה כהתפלגות האפס היה נותן סף מכויל כראוי (אולי ביתר מאמץ).